

財經新聞多標籤自動分類系統

1. 專案概述


背景：公司爬蟲蒐集大量財經新聞，需要自動化語義分類，以方便使用者尋找相對應標新聞

目標：在零人工標注的前提下，建立可擴展的多標籤自動分類 Pipeline，最終對全量新聞完成批次標注

資料規模：全量新聞十幾萬篇；Embedding 篩選後送入 LLM 標注的候選集去重後共 2,740 篇

核心挑戰：無任何人工標注資料、多標籤（一篇可對應多個標籤）、標籤數量多

2. 資料流程圖



3. 資料清洗 Data Cleaning

爬蟲抓取的原始新聞內文為 Markdown 格式，直接送入 Embedding 模型會引入大量雜訊，影響語義向量的準確性。清洗步驟如下：

- 移除 Markdown 語法：去除網址、圖片標記、標題符號等非語義內容，保留純文字

- 篩除過短文章：低於門檻字數的文章資訊量不足，無法有效判斷語義類別

清洗後的純文字才進行 Embedding，確保相似度計算基於文章的真實語義內容。

4. 標籤庫設計

自行定義 36 個財經語義標籤，並為每個標籤撰寫英文語義定義。

為什麼要寫定義而不只是標籤名稱：

單純的標籤名稱語義模糊，Embedding 模型和 LLM 都可能產生偏差。明確的語義定義能讓相似度篩選更精準，也讓 LLM 標注時有明確的語義邊界可以參考。

標籤舉例：

"Global Economy":

"Global macroeconomic outlook, world economic growth, \ international trade volume, global recession or recovery, \ IMF World Bank forecasts",

"Monetary Policy":

"Central bank interest rate decisions, Fed ECB BOJ policy, \ quantitative easing or tightening, money supply, \ rate hike or cut announcements"

5. Embedding 相似度篩選

Embedding 模型：paraphrase-multilingual-MiniLM-L12-v2

這個階段的目的只是篩選候選集，不是最終分類。MiniLM 速度快、成本低，適合大量文章的初步相似度比對。

做法：

- 對所有標籤定義與全量新聞分別進行 Embedding
- 計算每篇新聞與每個標籤的 Cosine Similarity
- 為每個標籤篩選相似度最高的前 150 篇新聞作為候選集

為什麼用相似度篩選而非隨機抽樣：

初期採隨機抽樣時，候選集中各標籤的新聞分布極不均勻，部分標籤樣本數過少導致 LLM 標注品質不穩定。改用相似度篩選後，每個標籤都有足夠且高相關的候選新聞，大幅提升訓練資料品質。

6. LLM Zero-shot 標注

工具： Groq LLM API (llama-3.1-8b-instant)

做法：

將標籤名稱與語義定義一併寫入 Prompt，要求 LLM 為每篇候選新聞貼上 1-5 個最相關的標籤。

Prompt 設計：

```
prompt = f"""You are a financial news analyst tagging articles for investors.
```

```
Choose 1 to 5 labels that best describe this article.
Use the definitions to guide your selection.
```

```
【rules】
```

1. Use ONLY labels provided in the library. Do NOT invent new tags or use variations.
2. Rank labels from highest to lowest relevance.
3. If a label has only a weak or incidental connection to the article, DISCARD it. Quality over quantity.
4. Always prioritize specific technical/industry labels over generic categories.
5. If the article is not finance-related or no labels meet the high-relevance threshold, return an empty array [].

6. Specific Label Logic -> Stocks: Apply ONLY for general market trends or broad index movements.

If specific sectors are mentioned, prioritize technical tags (e.g., Semiconductor, AI).

7. Return a minimum of 1 and a maximum of 5 labels.

【Label Definitions】

{labels_with_def}

【News title】

{title}

【News content】

{text[:1500]}

【Outputs】

Return the result in a clean JSON array format: DO NOT include any Markdown tags or explanation text.

Example: ["Federal Reserve", "Interest Rates"]

Results: ""

設計重點：

- 把標籤定義寫進 Prompt 而非只給標籤名稱，引導 LLM 依語義邊界標注，降低標籤混淆率
- 限制輸出 1-5 個標籤，若新聞非財經相關新聞或找不到適合的標籤就不要勉強貼

7. 模型訓練

Embedding 模型：BAAI/bge-multilingual-gemma2

為什麼訓練階段換成 BGE：

實驗測試顯示 Embedding 模型的選擇會直接影響 SVM 分類結果。BGE Multilingual 對


多語言財經文本的語義捕捉能力優於 MiniLM，使用相同訓練資料但換用 BGE 後模型指標有顯著提升。

為什麼選 LinearSVM：

LLM 推論成本高、速度慢，不適合十幾萬篇新聞的批次標注。以 LLM 標注結果訓練輕量的 LinearSVM，在保持準確率的前提下大幅降低推論成本，具備生產環境的可擴展性。

評估結果：

	Precision	Recall	F1-score
micro avg	0.75	0.79	0.77
macro avg	0.73	0.74	0.73
weighted avg	0.75	0.79	0.77
samples avg	0.77	0.80	0.76



8. 部署與產出

模型訓練完成後儲存，以 BAAI/bge-multilingual-gemma2 對全量未標注新聞進行 Embedding，載入 LinearSVM 模型進行批次標注，實現財經新聞語義分類的全自動化。

進行中：個股提取

後續計畫從文章內文中提取提及的個股代號，例如台積電（2330）、Apple（AAPL），進一步豐富新聞的結構化資訊。

9. 挑戰與學到的事

1. 隨機抽樣 vs 相似度篩選

初期用隨機抽樣產生候選集，導致標籤分布嚴重不均，部分標籤幾乎沒有訓練樣本。改用 Cosine Similarity 篩選後，每個標籤的候選新聞都具備高相關性，訓練資料品質顯著提升。這個經驗說明訓練資料的構成方式比資料量本身更重要。

2. Embedding 模型的選擇影響分類結果

實驗發現篩選階段和訓練階段使用不同 Embedding 模型效果更好，MiniLM 負責快速篩選，BGE Multilingual 負責高品質特徵提取。兩個模型各司其職，在成本與效能之間取得平衡。

3. 標籤定義的精確性決定標注品質

初期只給標籤名稱時，LLM 標注結果不穩定，同一篇文章多次標注結果不一致。加入語義定義後標注一致性顯著提升，說明在多標籤分類任務中，類別的明確定義比類別數量本身更關鍵。